

TD 2 Télédétection Radar

Analyse de séries temporelles d'images Sentinel-1
avec SNAP

TOULOUSE INP-ENSAT
M2 SIGMA – 2025/2026

Étudiants :

Thiago GAMA DE LIMA
Justin LAFARGUE
Djiby Diallo

Enseignante :

Yousra HAMROUNI

Date :

22 janvier 2026

TD 2 Télédétection Radar

INTRODUCTION DU RAPPORT : TD 2 TÉLÉDÉTECTION RADAR

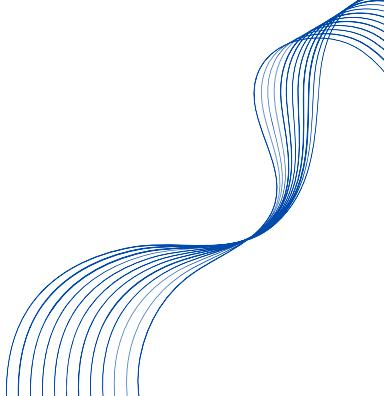
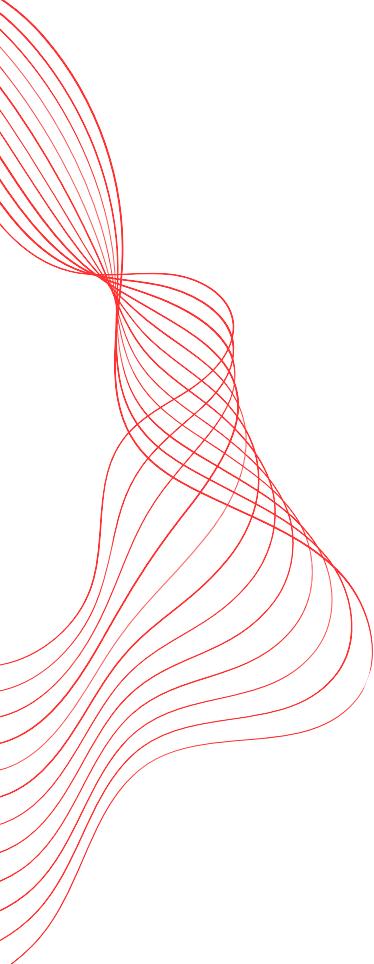
Ce travail pratique s'inscrit dans le cadre de l'analyse de séries temporelles d'images radar Sentinel-1 à l'aide du logiciel SNAP . L'objectif principal est d'étudier l'occupation du sol et ses évolutions sur une zone d'étude spécifique : la commune de Saint Nicolas de la Grave, située dans le département du Tarn-et-Garonne.

Pour ce faire, nous utilisons une série d'images acquises entre le 1er mai 2017 et le 30 septembre 2017. Ces données, initialement téléchargées sur la plateforme GEODES, sont des produits de type GRD (Ground Range Detected) acquis en mode IW (Interferometric Wide Swath) avec des polarisations VV et VH, sur une orbite ascendante (numéro 132). Afin d'optimiser les temps de calcul, les images utilisées ont été préalablement découpées selon l'emprise de la zone d'étude.

La méthodologie suivie dans ce rapport s'articule autour de plusieurs axes majeurs :

1. La mise en place d'une chaîne de pré-traitement automatisée via l'outil Graph Builder et le mode Batch Processing.
2. Le traitement et l'analyse multi-temporelle pour observer la dynamique des surfaces.
3. Le suivi des cycles saisonniers à travers l'étude de la rétrodiffusion radar.
4. L'application de méthodes de classification, à la fois non-supervisée (K-means) et supervisée (Random Forest), pour cartographier l'utilisation du sol.
5. Enfin, l'initiation à l'automatisation via un pipeline de traitement en langage Python.

Ce rapport présente les résultats obtenus à chaque étape, les captures d'écran justificatives ainsi que les réponses détaillées aux questions techniques posées durant le TD.



Partie I

1. Introduction

Objectif de la séance

Ce TD a pour objectif d'analyser une série temporelle d'images radar Sentinel-1 (produits GRD) à l'aide du logiciel SNAP. Il vise à mettre en place une chaîne de pré-traitement automatisée, à réaliser des analyses multi-temporelles et saisonnières, et à appliquer des méthodes de classification non-supervisée et supervisée afin d'étudier l'occupation du sol et ses dynamiques.

PARTIE 1 : PRÉ-TRAITEMENT ET AUTOMATISATION (BATCH PROCESSING)

A. 1 Visualisation

1 / Métadonnée de l'image traitée :

Image 3 : 06/07/2017

Angles d'incidences :

Incidence near : 30.42790185207303

Incidence far : 46.154288577707725

Le nom de la mission : SENTINEL-1A ascii
Satellite mission

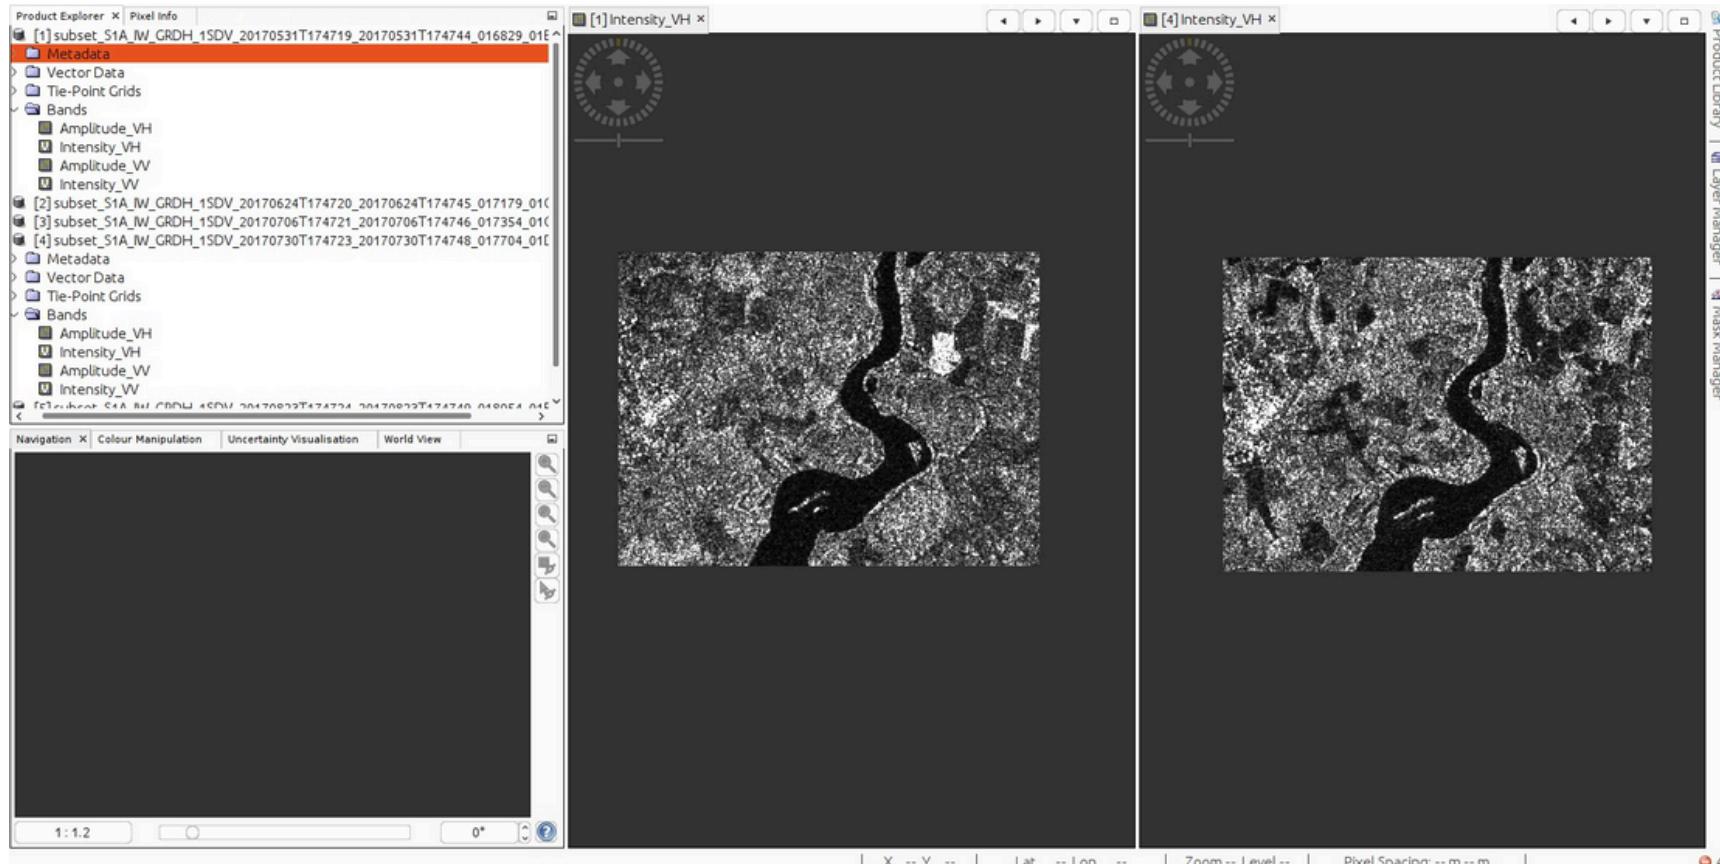
Le nombre de pixels de l'image en x : **8054**

Le nombre de pixels de l'image en y : **5348**

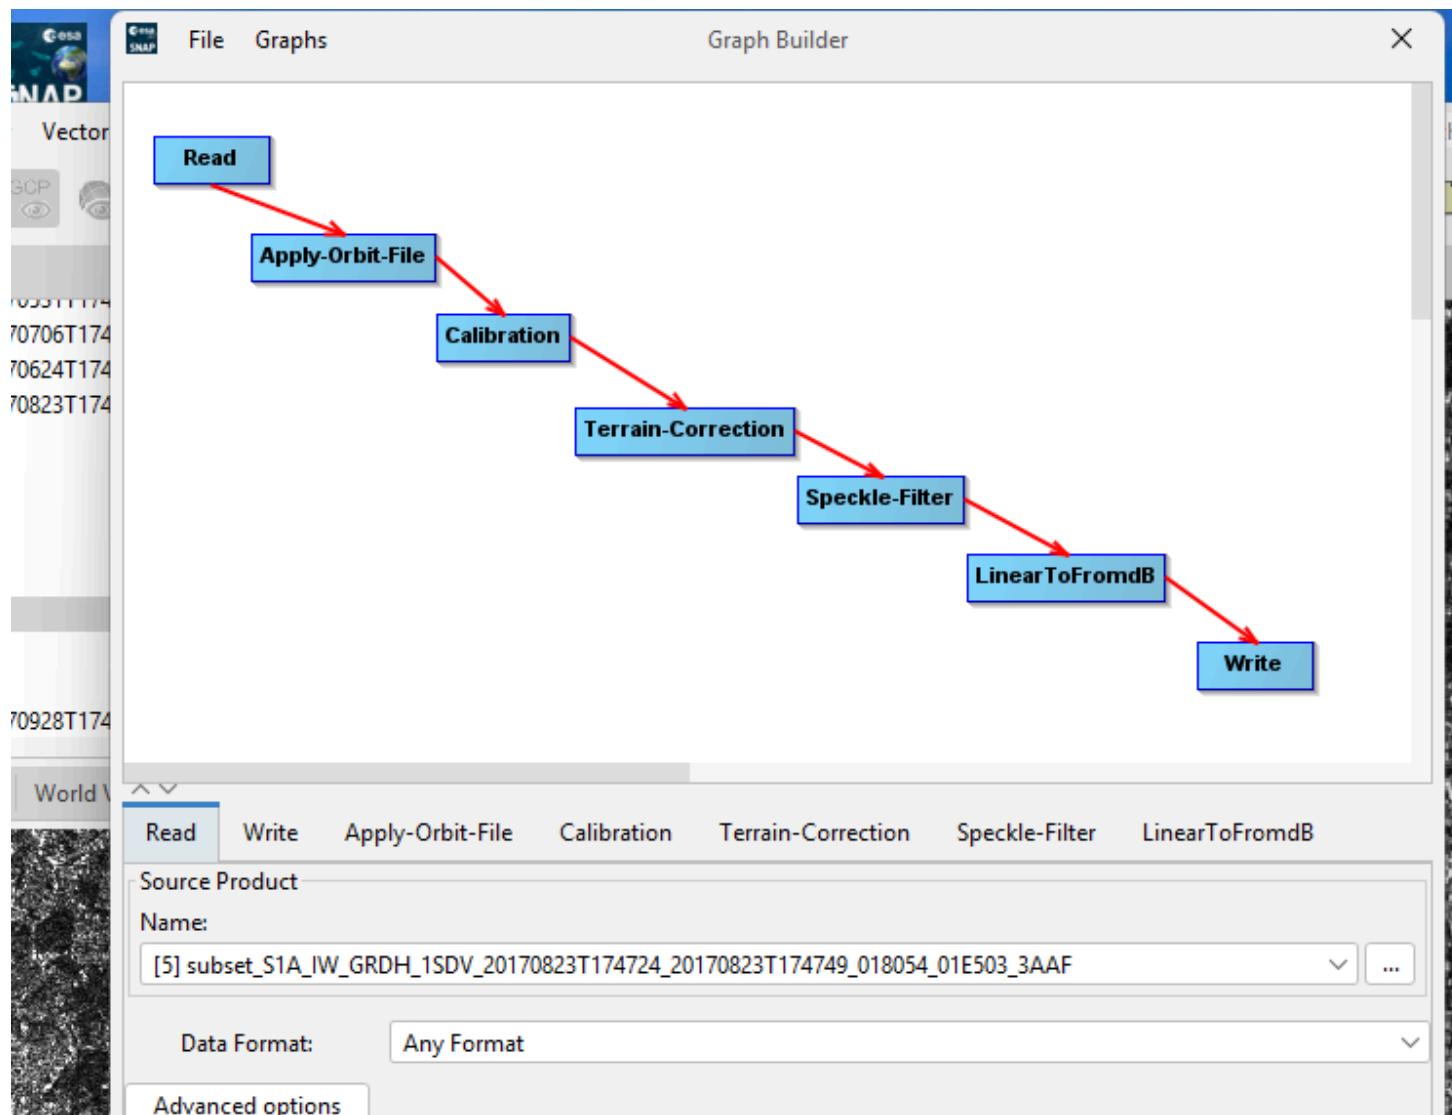
incidence_near	30.42790185207303	
incidence_far	46.154288577707725	
SENTINEL-1A	ascii	Satellite mission
subset_offset_x	8054	
subset_offset_y	5348	

A.2 Comparaison visuelle

Affichez côté à côté les images d'intensité en polarisation VH du **31/05/2017** et du **30/07/2017** :



B. Chaîne de traitement avec Graph Builder



C. Batch processing

Le temps total du traitement est de 17s

Batch Processing : myGraph.xml

[Nodeld: Read] No product reader found for file '/home/AD/ddo4019'.

I/O Parameters	Apply-Orbit-File	Calibration	Terrain-Correction	Speckle-Filter	LinearToFromdB	Write
File Name	Type	Acquisition	Track	Orbit		
subset_S1A_IW_GRDH_1SDV_201...	GRD	31May2017	132	16829		
subset_S1A_IW_GRDH_1SDV_201...	GRD	24Jun2017	132	17179		
subset_S1A_IW_GRDH_1SDV_201...	GRD	06Jul2017	132	17354		
subset_S1A_IW_GRDH_1SDV_201...	GRD	30Jul2017	132	17704		
subset_S1A_IW_GRDH_1SDV_201...	GRD	23Aug2017	132	18054		
subset_S1A_IW_GRDH_1SDV_201...	GRD	28Sep2017	132	18579		

File Graphs

Processing completed in 17 seconds

I/O Parameters | Apply-Orbit-File | Calibration | Terrain-Correction | Target Product

Name: subset_S1A_IW_GRDH_1SDV_20170823T174724_20170823T17474

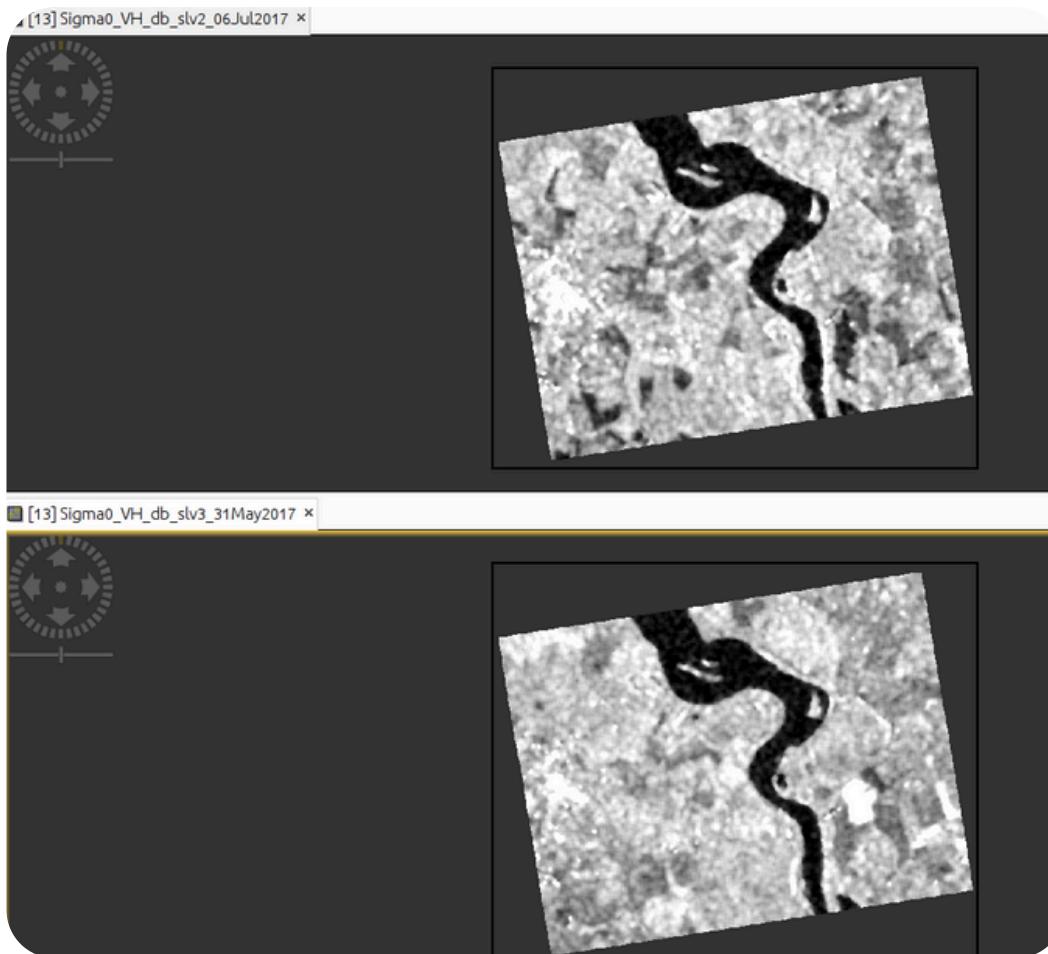
Save as: BEAM-DIMAP

Directory: /home/AD/BEAM-DIMAP

Partie II

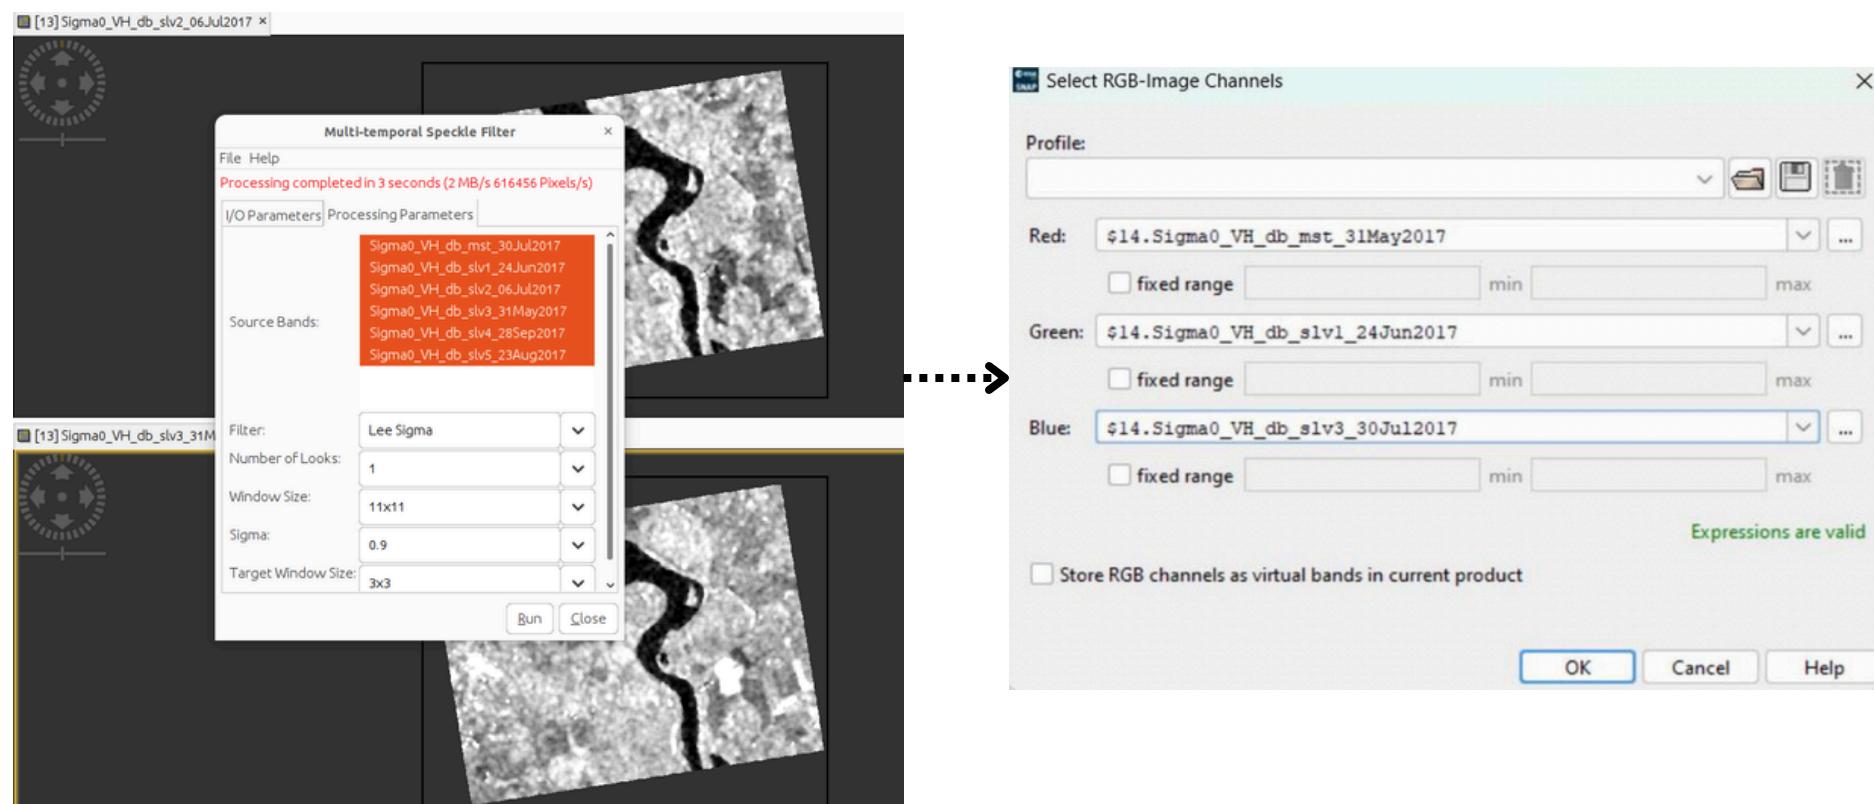
Comparaison 31/05 – 06/07

Le cours d'eau reste sombre sur les deux dates, ce qui est cohérent avec une faible rétrodiffusion de l'eau en polarisation VH. En revanche, les zones terrestres présentent des variations de texture et de luminance entre le 31/05 et le 06/07, traduisant une évolution de l'état de surface (humidité des sols, développement ou dessèchement de la végétation). Le stack temporel permet ainsi de mettre en évidence des changements saisonniers.



Filtrage multi-temporel du speckle

Après avoir appliqué le filtre spatio-temporel sur l'ensemble de six bandes du stack, un affichage en RGB de l'information multi-temporelle du stack est réalisé. Chaque bande colorée de RGB correspond à une valeur du coefficient de rétrodiffusion (σ_0 VH) à la date correspondante.

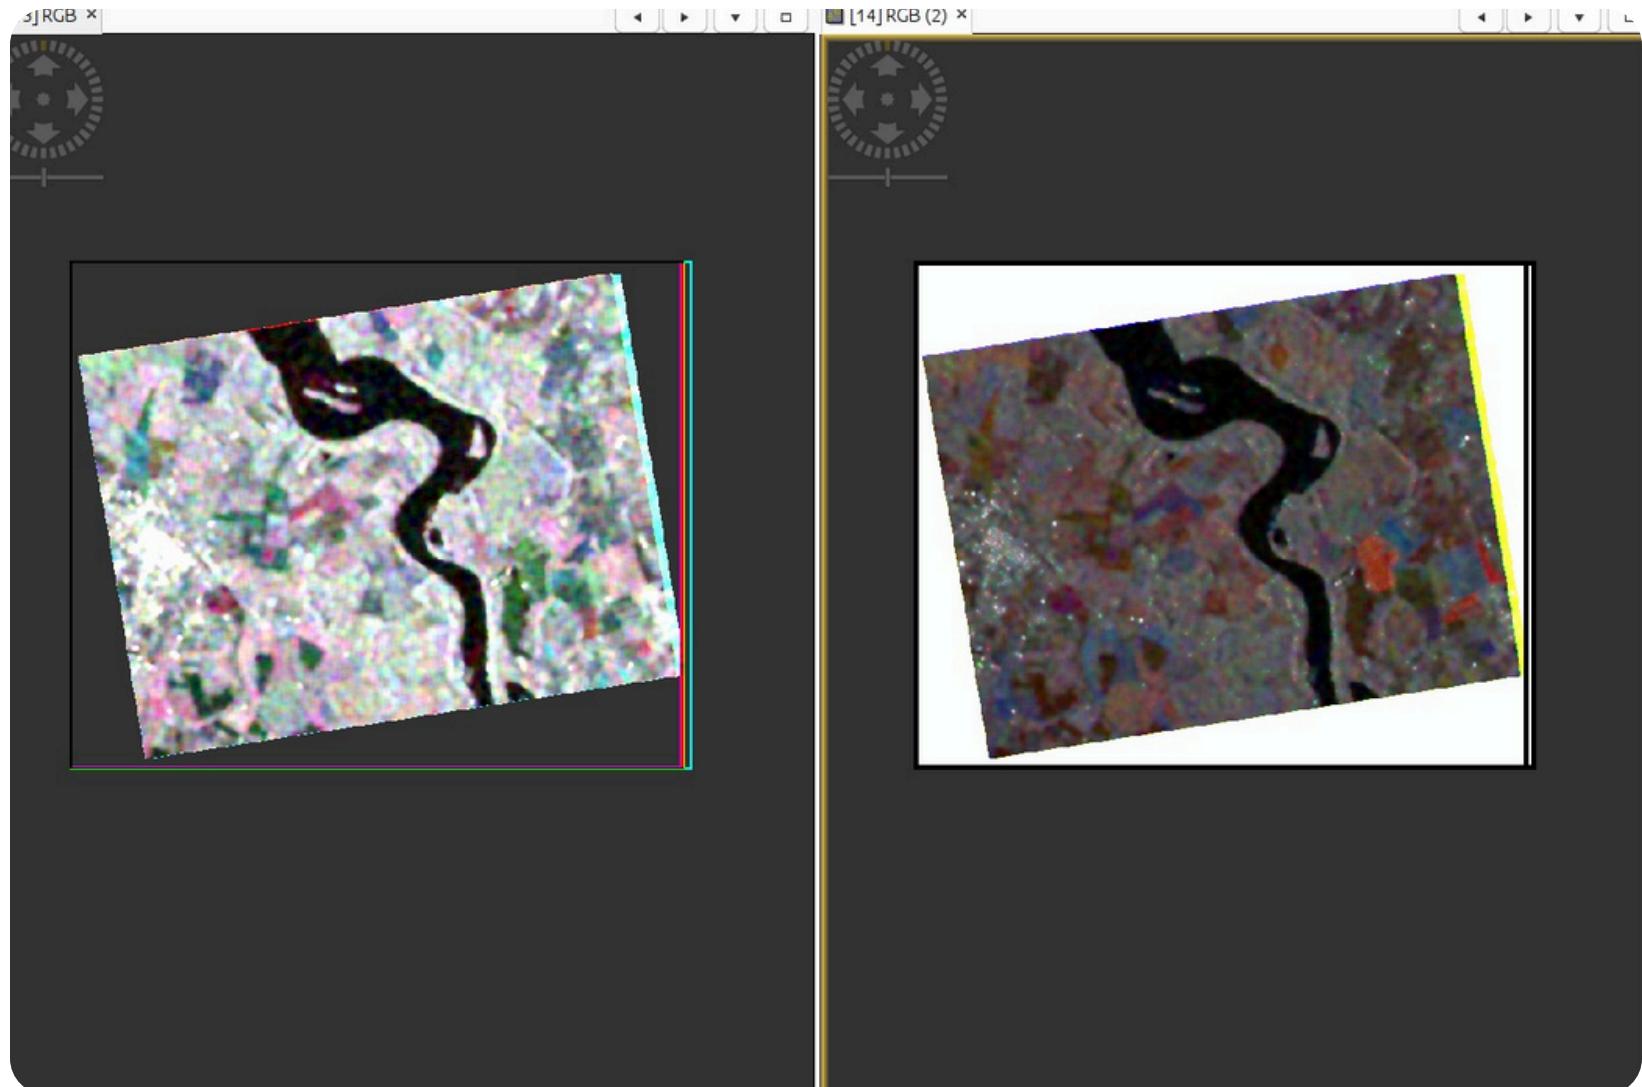


Compositions colorées multi-temporelles

Les deux images affichées dans la figure ci-dessous correspondent respectivement :

[13] RGB : C'est la composition colorée RGB du stack avant filtrage spatiotemporelle (multi-Speckle)

[14] RGB : C'est la composition colorée RGB du stack après filtrage spatiotemporelle



Filtrage multi-temporel du speckle

Comment apparaissent les coefficients de rétrodiffusion les plus élevés ? À quoi cela correspond ? De même pour les valeurs les plus faibles.

Les pixels présentant les coefficients de rétrodiffusion les plus élevés apparaissent clairs ou fortement colorés dans la composition RGB. Ils correspondent à des surfaces capables de renvoyer efficacement l'énergie radar vers l'antenne, en raison de mécanismes de diffusion favorables.

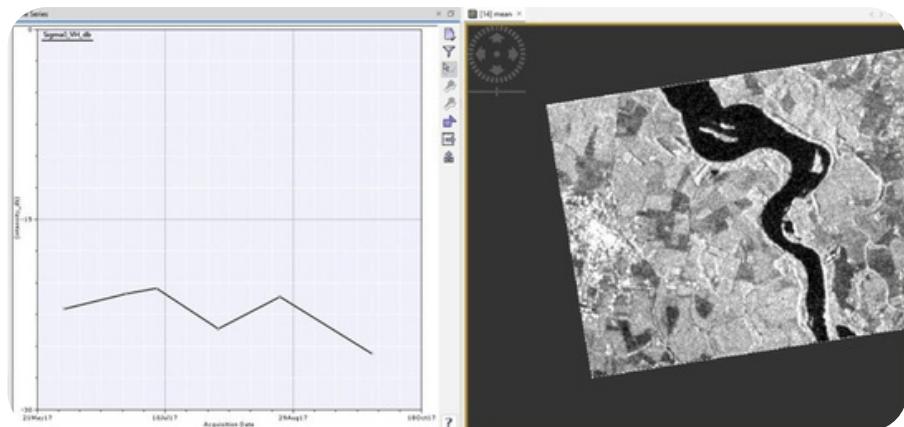
Il s'agit en particulier :

- I)** des zones urbaines et infrastructures, où les géométries angulaires génèrent des phénomènes de double rebond produisant des retours très intenses ;
- II)** de la végétation dense ou structurée, caractérisée par une diffusion volumique et une dépolarisation marquée, efficacement détectée en polarisation VH ;
- III)** de certains sols rugueux et/ou humides, pour lesquels l'augmentation de la constante diélectrique et la rugosité de surface amplifient la rétrodiffusion radar.

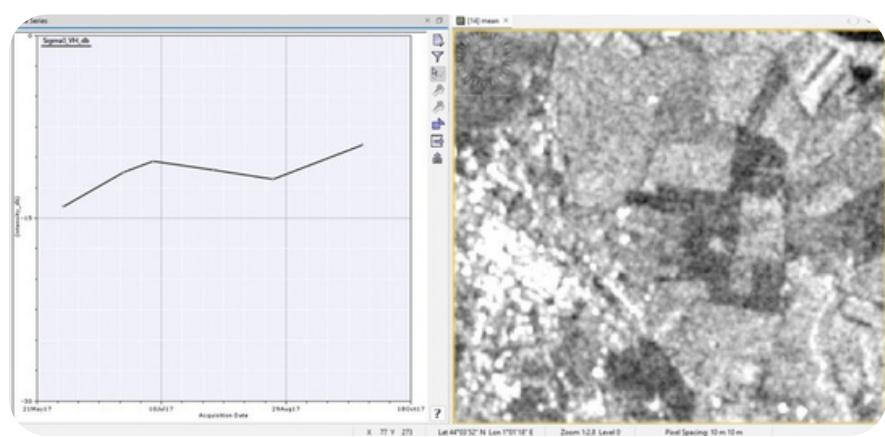
À l'inverse, les valeurs de rétrodiffusion les plus faibles apparaissent sombres et sont principalement associées aux surfaces lisses, en particulier les plans d'eau. Dans ce cas, la réflexion spéculaire dirige l'énergie incidente hors de la direction du capteur, entraînant un retour radar très faible.

Enfin, l'application d'un filtrage speckle permet de réduire le bruit granuleux inhérent à l'imagerie radar cohérente, d'homogénéiser les zones radiométriquement uniformes et d'améliorer significativement la lisibilité des contrastes spatiaux ainsi que l'interprétation des variations temporelles de la rétrodiffusion.

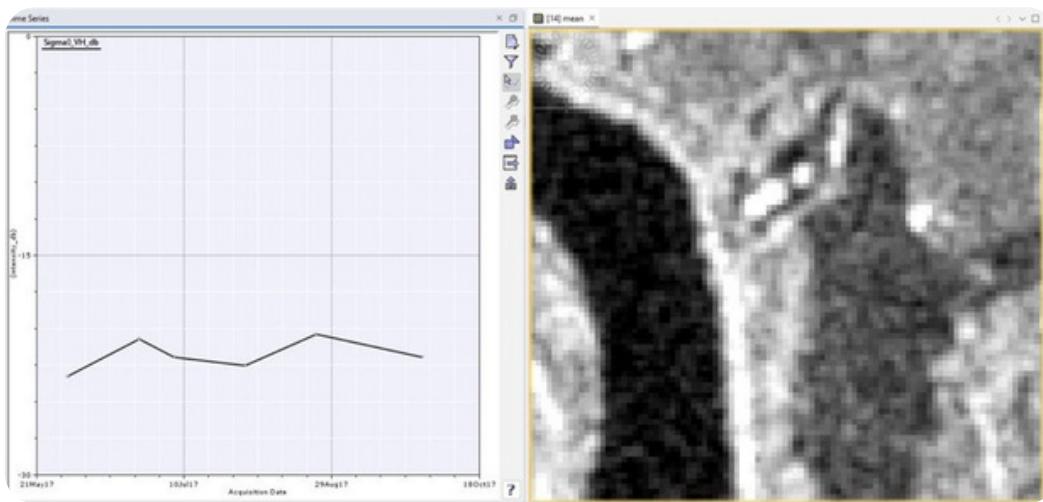
Calcul de statistiques multi-temporelles profil temporel d'un pixel



Profil temporel d'un pixel choisi au hasard dans la zone du cours d'eau: Valeurs d'intensité faibles et variables au cours du temps



Profil temporel d'un pixel choisi au hasard dans une zone urbaine : Valeurs plus ou moins élevées supérieures à - 15 db avec une variation moyenne entre les mois



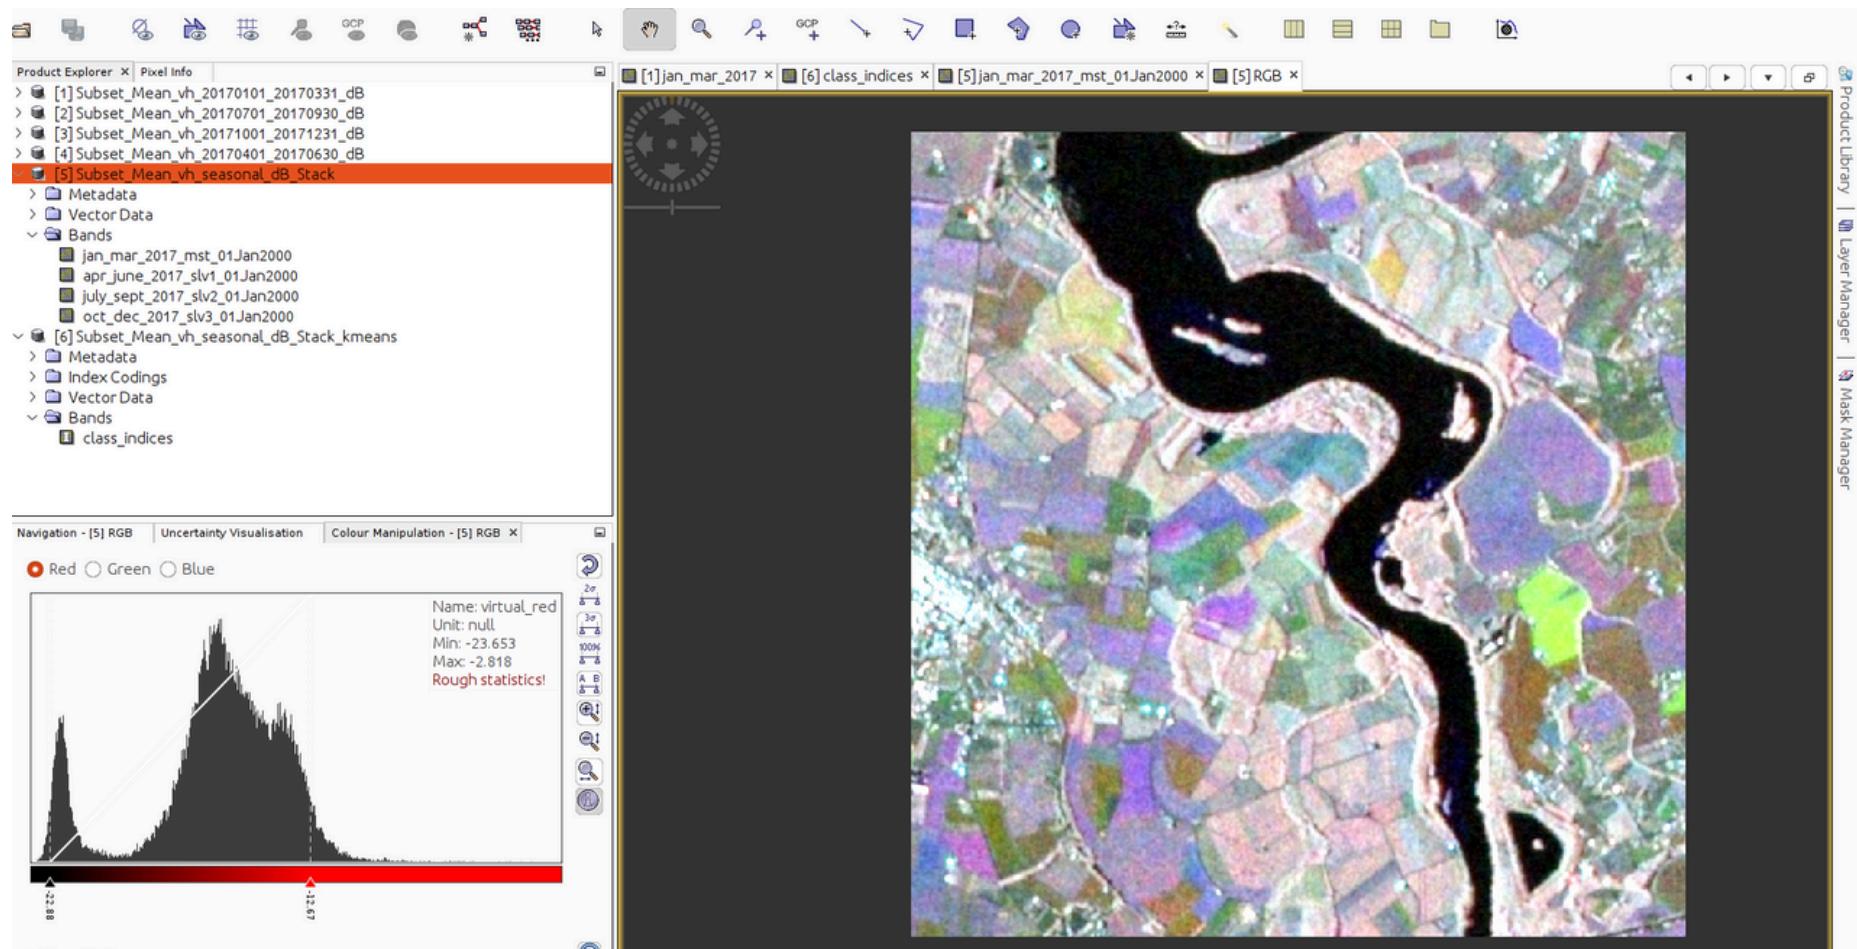
Profil temporel d'un pixel situé sur une zone forestière très humide (faibles valeurs de rétrodiffusion)

Partie III

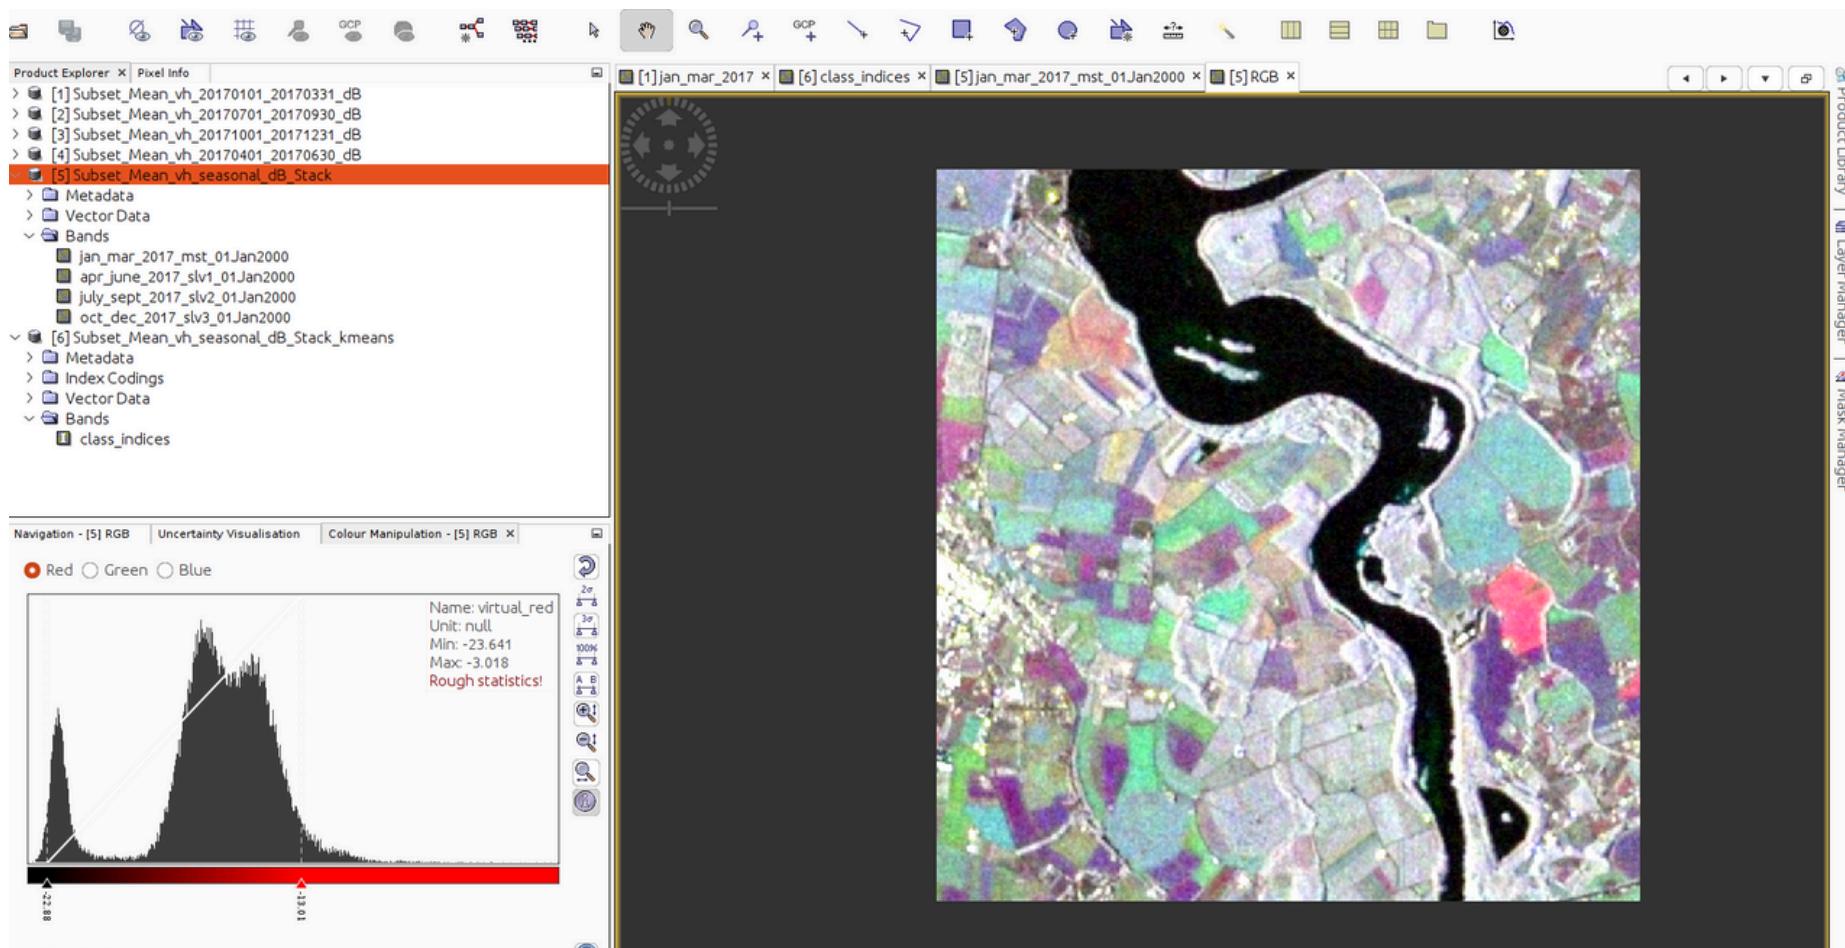
PARTIE 3 : DYNAMIQUES SAISONNIÈRES ET CLASSIFICATION

1. À partir du Stack des moyennes saisonnières, voici les deux compositions colorées :

Une composition représentant : Hiver - Printemps - Été



Une composition représentant : Printemps -Été - Automne



2. En utilisant l'outil Pixel Info, voici les plages approximatives des valeurs de sigma0 VH pour les trois principales classes d'occupation des sols :

Eau : <-20 db

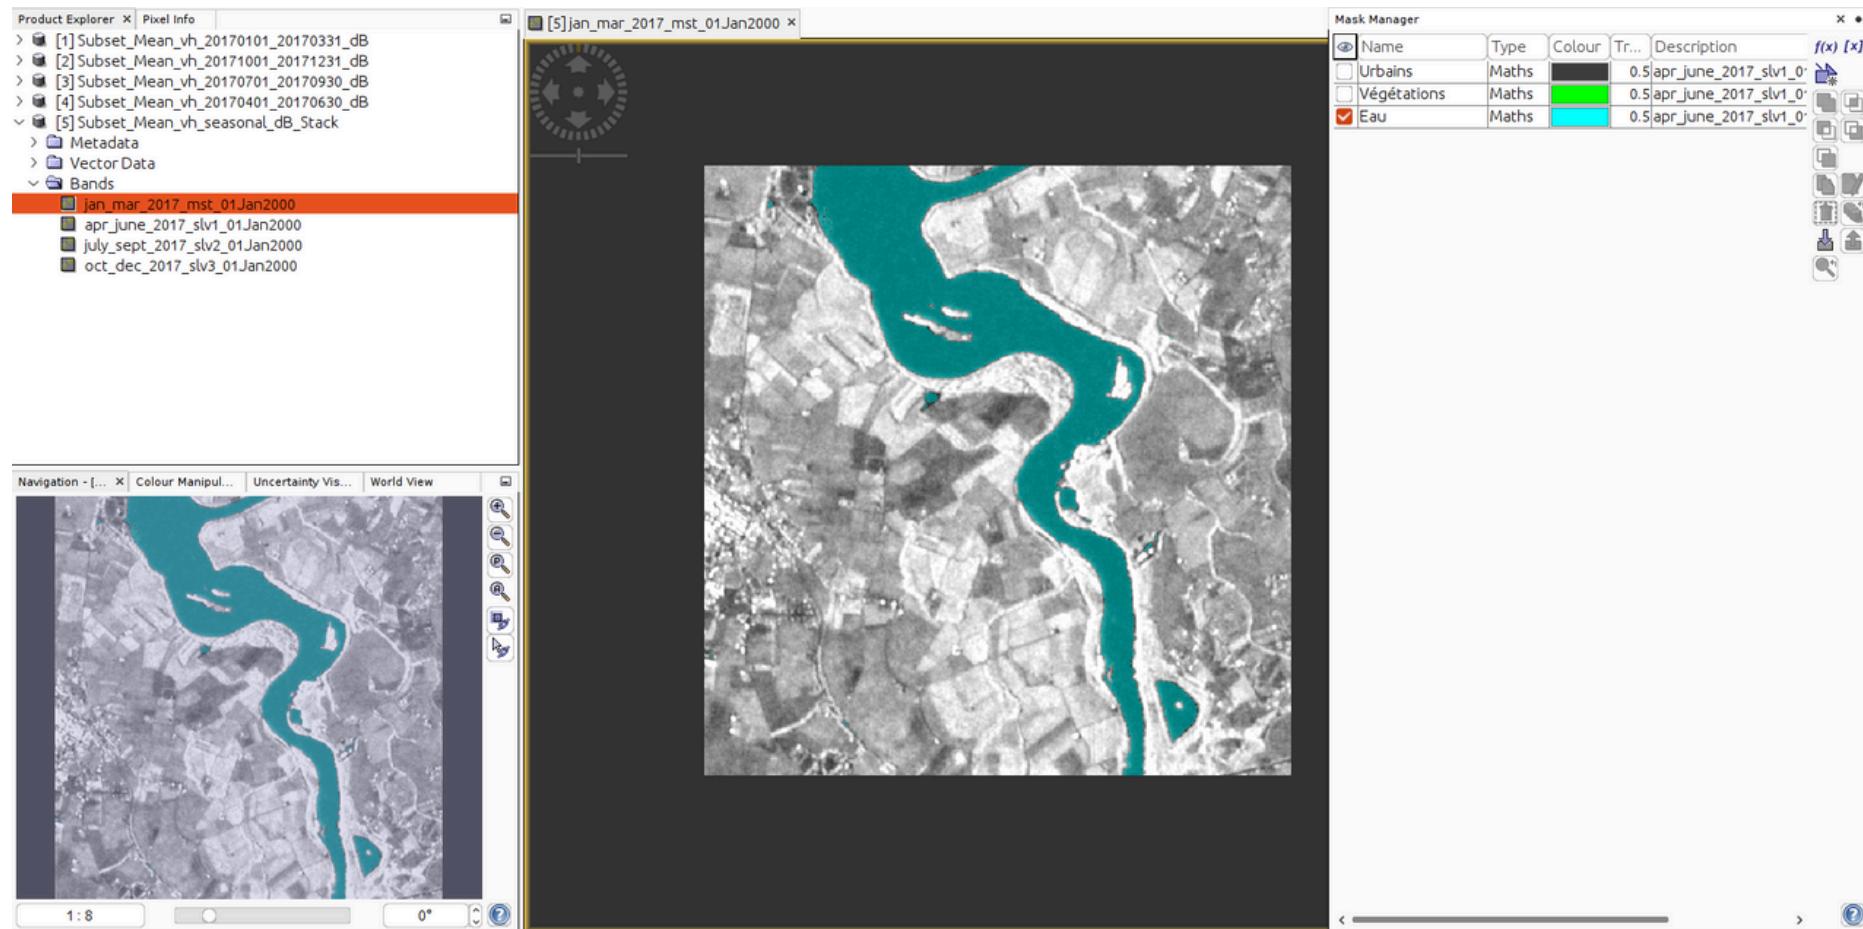
Végétation : [-20 db : -10 db]

Zones urbaines : [-10 db : 0 db]

Mask Manager, affichez ces pixels en bleu

Les pixels affichés en bleu sur l'image résultat de mask Manager avec une faible valeur de rétrodiffusion (inférieurs à -20 db) correspondent à des surfaces d'eau.

Formule utilisée : apr_june_2017_slv1_01Jan2000 < -20



Deux autres occupations des sols à afficher

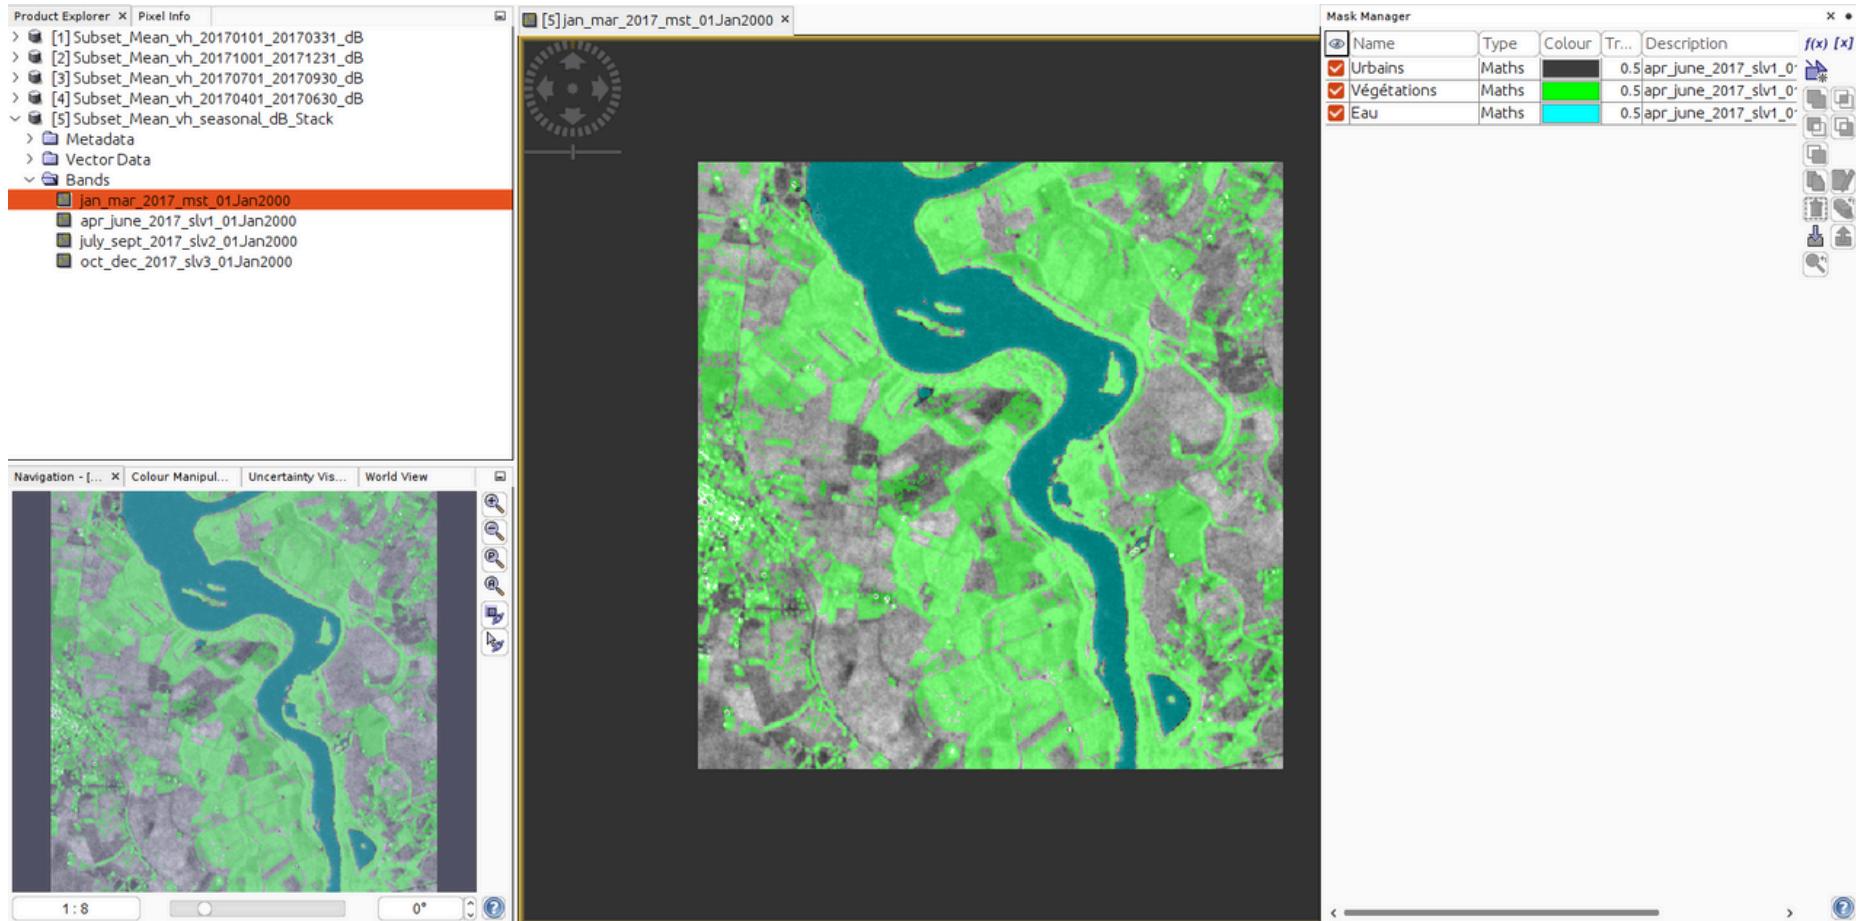
Formule utilisée :

Végétation

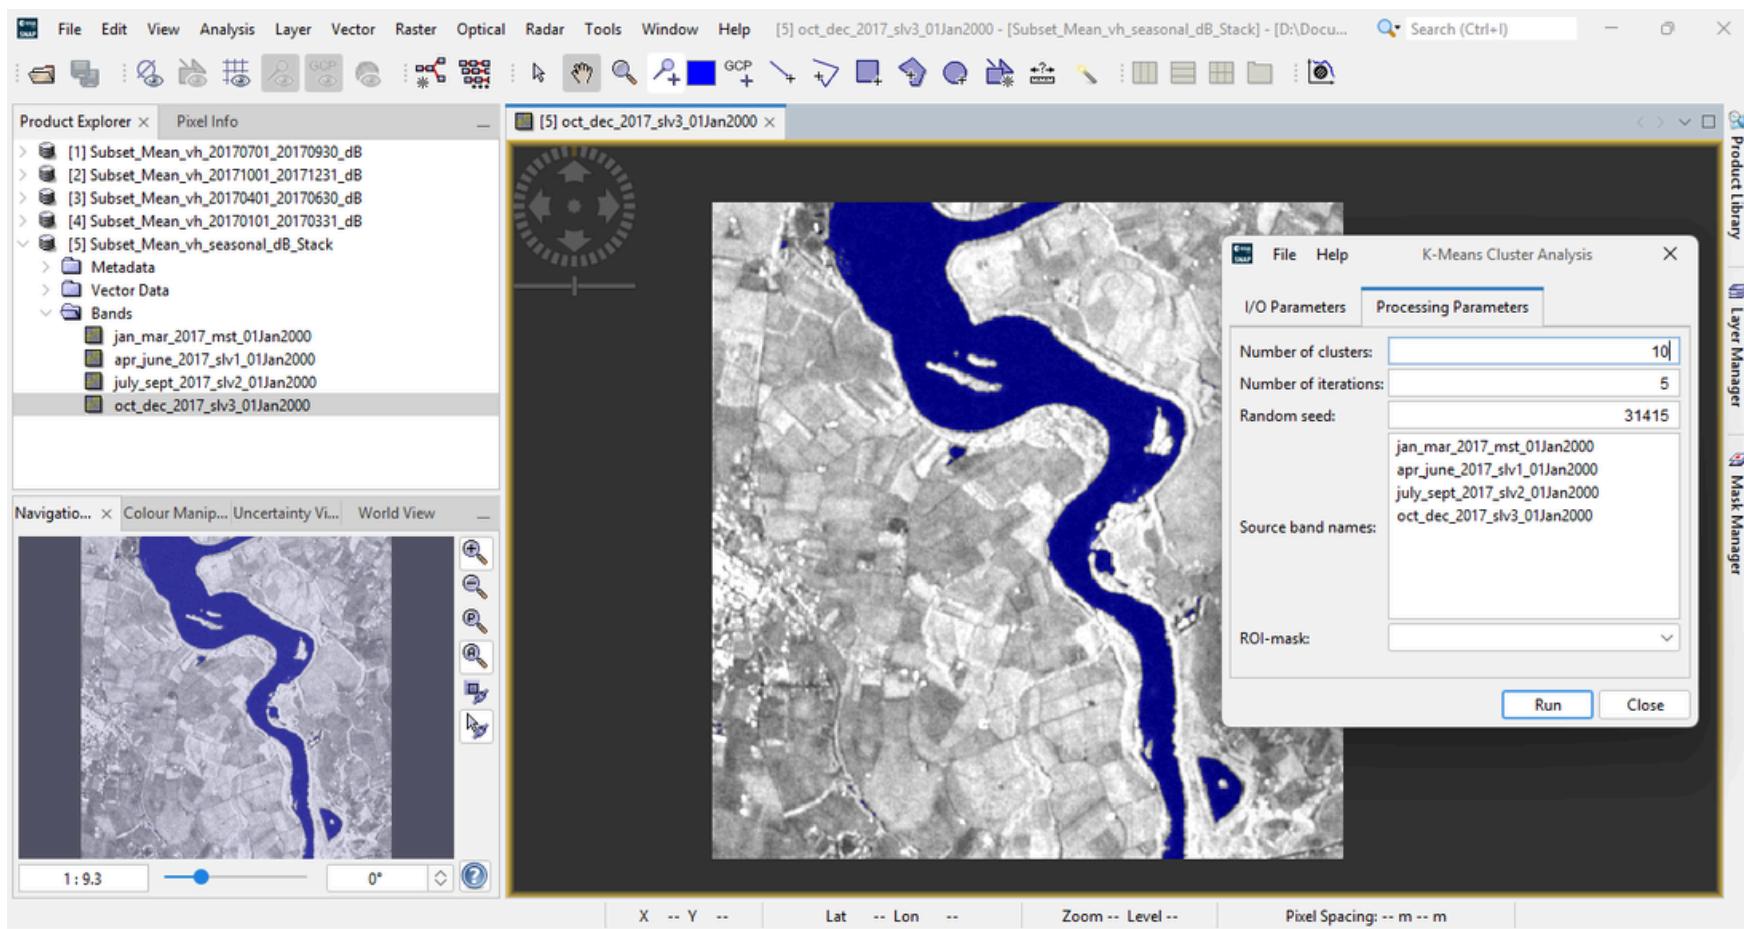
apr_june_2017_slv1_01Jan2000 > -16 and apr_june_2017_slv1_01Jan2000 < -10

Zones urbaines

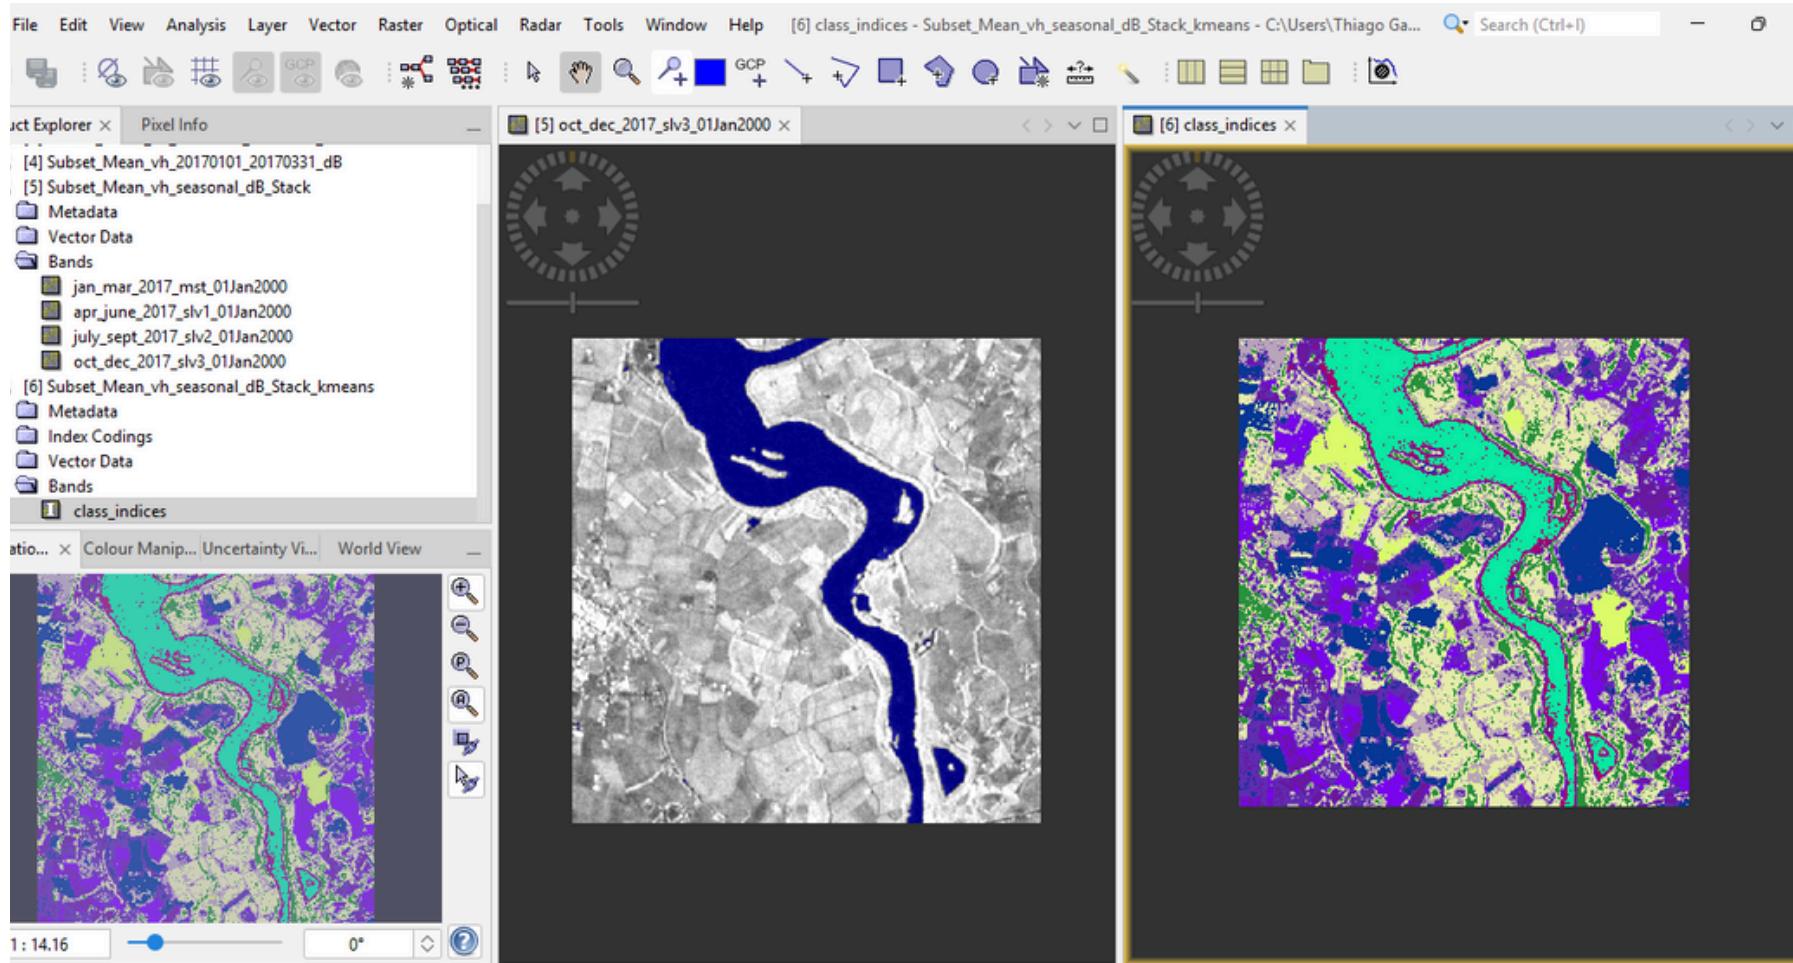
apr_june_2017_slv1_01Jan2000 > -8 and apr_june_2017_slv1_01Jan2000 < 0



Classification non-supervisée avec K-means

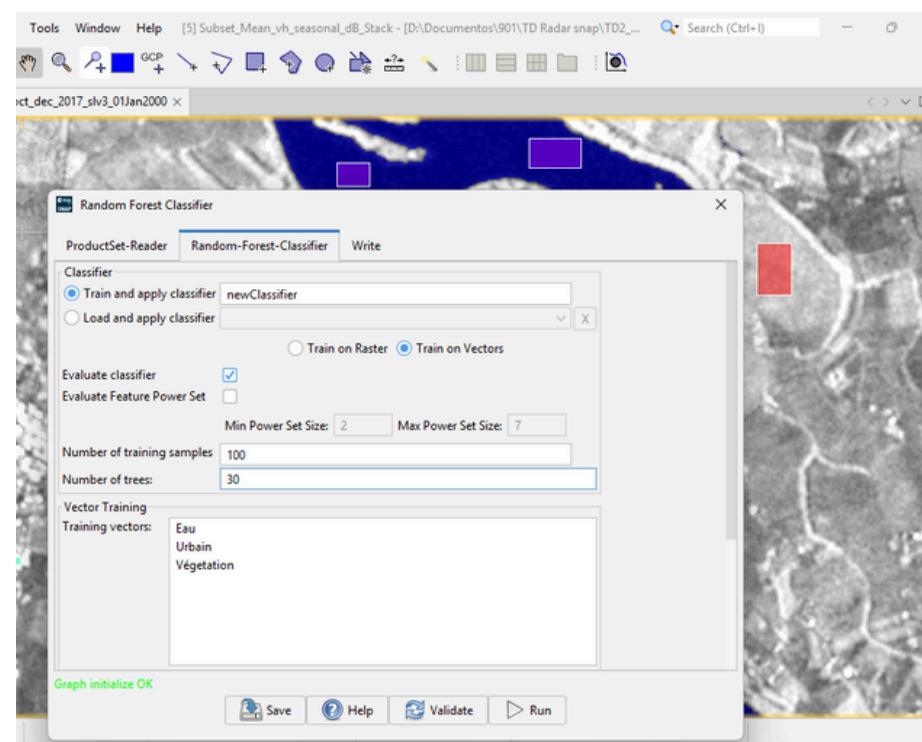
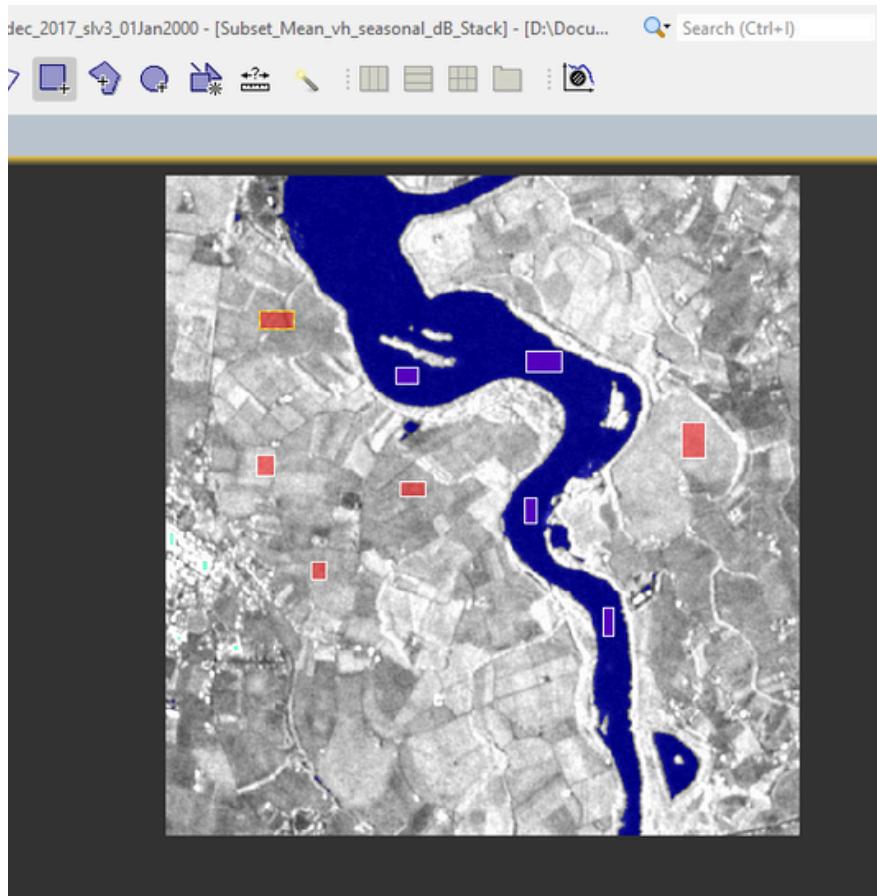


Classification non-supervisée avec K-means

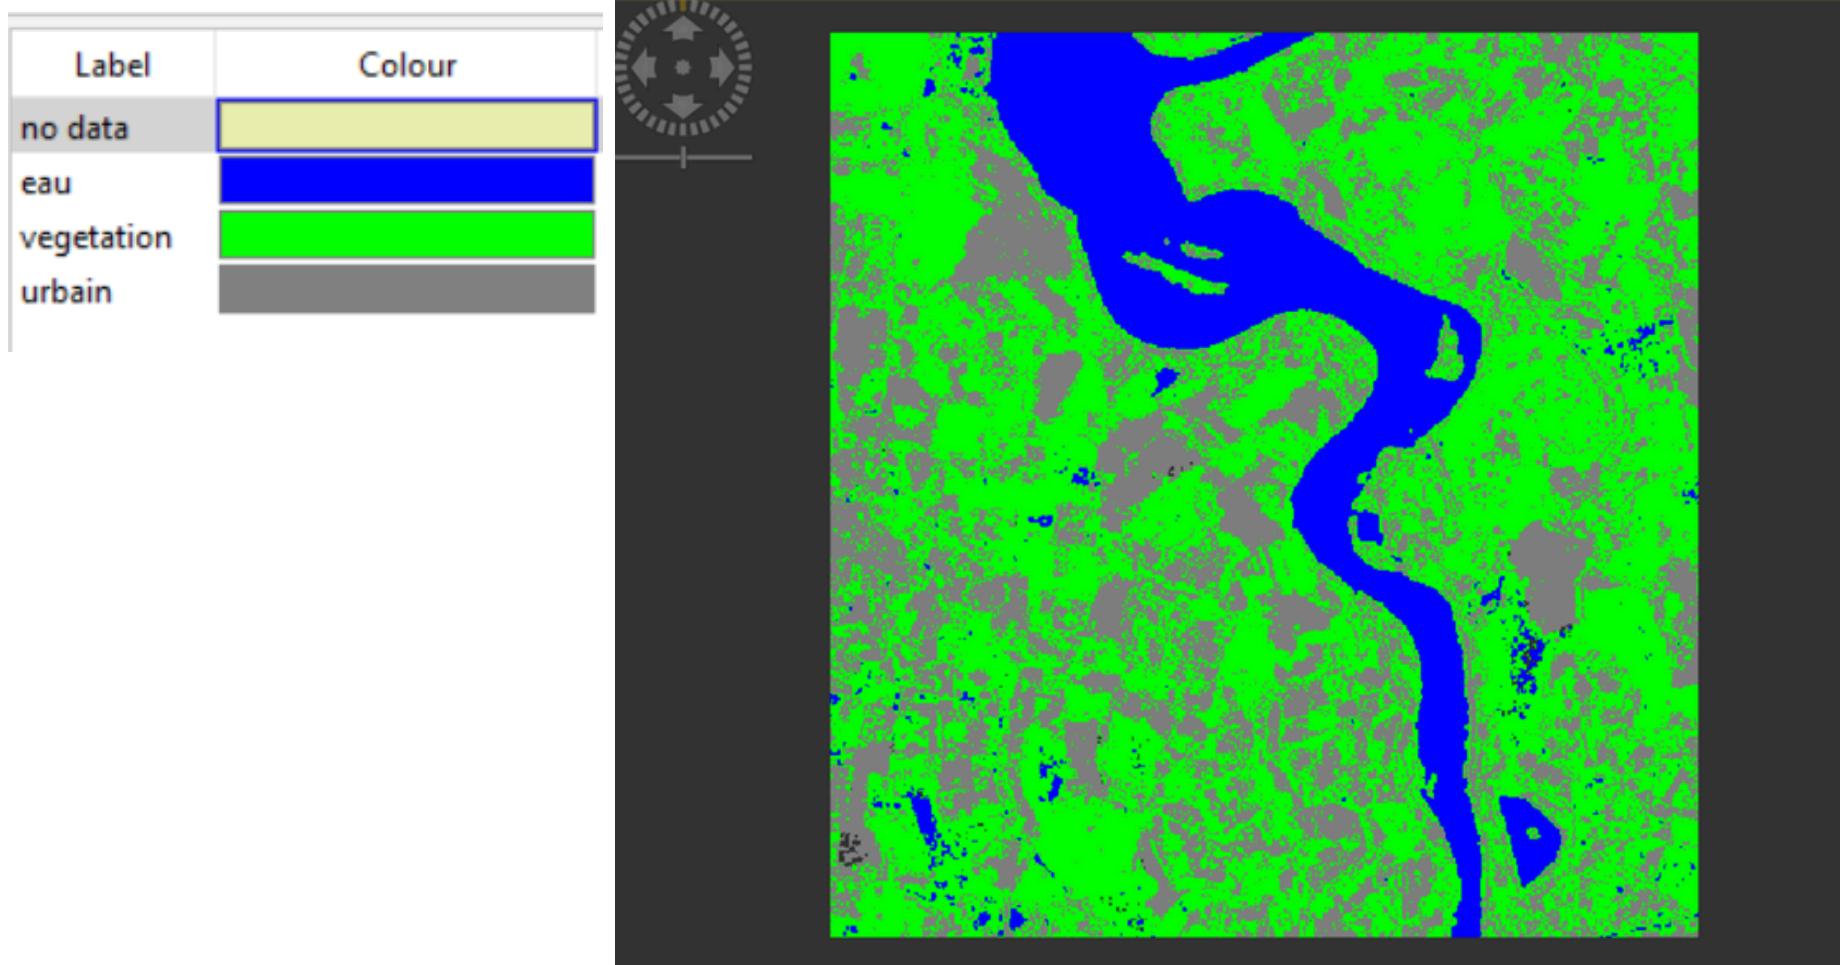


La classification K-means montre une nette structuration du paysage. Les zones urbaines sont identifiées par des clusters à forte rétrodiffusion constante, tandis que les surfaces d'eau sont isolées par des valeurs minimales stables. La structuration géométrique des pixels au centre de l'image révèle les parcelles agricoles, où le K-means a réussi à distinguer les types de cultures selon leur cycle de croissance (phénologie) capturé par les moyennes saisonnières.

Classification supervisée avec Random Forest



Classification supervisée avec Random Forest



L'interprétation graphique montre une excellente discrimination des classes majeures grâce à l'apprentissage supervisé. La carte de Random Forest est plus précise que la classification non-supervisée pour délimiter les zones bâties. Cependant, la carte de confiance révèle que les limites entre les parcelles agricoles et les zones d'eau présentent une incertitude plus élevée. Cela s'explique par la complexité du signal radar sur les zones de transition (humidité des berges, végétation basse) qui peuvent mimer la signature d'autres classes.

Résultats de la validation croisée

```
RandomForest classifier newClassifier

Cross Validation
Number of classes = 3
class 0.0: eau
accuracy = 1.0000 precision = 1.0000 correlation = 1.0000 errorRate = 0.0000
TruePositives = 33.0000 FalsePositives = 0.0000 TrueNegatives = 66.0000 FalseNegatives = 0.0000
class 1.0: vegetation
accuracy = 0.7374 precision = 0.5814 correlation = 0.5869 errorRate = 0.2626
TruePositives = 25.0000 FalsePositives = 18.0000 TrueNegatives = 48.0000 FalseNegatives = 8.0000
class 2.0: urbain
accuracy = 0.7374 precision = 0.6522 correlation = 0.5197 errorRate = 0.2626
TruePositives = 15.0000 FalsePositives = 8.0000 TrueNegatives = 58.0000 FalseNegatives = 18.0000

Using Testing dataset, % correct predictions = 73.7374
Total samples = 200
RMSE = 0.5124707431905383
Bias = -0.10101010101010101

Distribution:
class 0.0: eau           67      (33.5000%)
class 1.0: vegetation    67      (33.5000%)
class 2.0: urbain        66      (33.0000%)

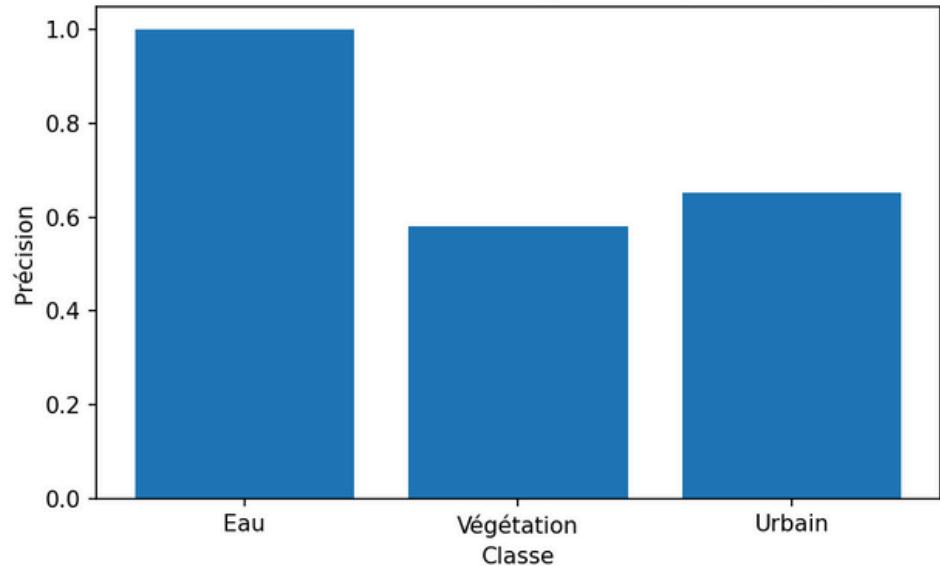
Testing feature importance score:
Each feature is perturbed 3 times and the % correct predictions are averaged
The importance score is the original % correct prediction - average
rank 1  feature 4 : oct_dec_2017_slv3_01Jan2000score: tp=0.2559 accuracy=0.1706 precision=0.2561 correlation=0.2565 errorRate=-0.1706 cost=-0.4933 GainRatio = 0.4070
rank 2  feature 3 : july_sept_2017_slv2_01Jan2000score: tp=0.2256 accuracy=0.1504 precision=0.2287 correlation=0.2467 errorRate=-0.1504 cost=-0.3838 GainRatio = 0.4129
rank 3  feature 2 : apr_june_2017_slv1_01Jan2000score: tp=0.1751 accuracy=0.1167 precision=0.1755 correlation=0.2084 errorRate=-0.1167 cost=-0.2541 GainRatio = 0.4346
rank 4  feature 1 : jan_mar_2017_mst_01Jan2000score: tp=0.1212 accuracy=0.0808 precision=0.1226 correlation=0.1554 errorRate=-0.0808 cost=-0.1560 GainRatio = 0.4154
```

Affichez la classification et la confiance associée et interprétez graphiquement les résultats

Matrice de confusion (valeurs)

	Eau	Végétation	Urbain
Eau	33	0	0
Végétation	8	25	18
Urbain	18	8	15

Confiance du classifieur (précision par classe)



Le graphique de confiance montre que la classe eau est parfaitement reconnue par le modèle (précision = 100 %). Cela signifie que tous les pixels classés comme eau sont corrects, ce qui indique que ses caractéristiques spectrales et radar sont très distinctes des autres classes.

En revanche, les classes végétation ($\approx 58\%$) et urbain ($\approx 65\%$) présentent une confiance nettement plus faible. La matrice de confusion confirme cette observation : un nombre important de pixels de végétation est classé comme urbain et inversement. Cette confusion s'explique par des signatures spectrales proches (bâtiments entourés de végétation, sols nus, zones périurbaines).

Ainsi, graphiquement :

La diagonale est très marquée pour la classe eau \rightarrow classification stable.

Elle est plus diffuse pour végétation et urbain \rightarrow incertitude élevée.

Conclusion : le modèle est très performant pour détecter l'eau, mais nécessite des variables supplémentaires (indices spectraux, plus de dates, ou données texturales) pour mieux séparer les zones urbaines et la végétation.